



¿CÓMO IMPLEMENTAR UN MODELO DE MACHINE LEARNING, APOYADO EN LA ESTRATEGIA METODOLÓGICA FIGS PARA PREDECIR ACCESIONES DE FRIJOL DEL GÉNERO PHASEOLUS VULGARIS CON POTENCIAL ADAPTATIVO A CONDICIONES DE SEQUÍA Y ANEGAMIENTO, UTILIZANDO VARIABLES ECOGEOGRÁFICAS Y TÉCNICAS DE MINERÍA DE DATOS?

Documento de Propuesta de trabajo integrador

GUILLERMO ANDRÉS HERNÁNDEZ ZAMORA
202401736
guillermo.hernandez@correounivalle.edu.co

Director: Víctor Andrés Bucheli Guerrero, Ph.D.
Victor.bucheli@correounivalle.edu.co

Co-Director: Diego Felipe Conejo Rodriguez , Ph.D.
dfconejero@unal.edu.co

Facultad de Ingeniería
Escuela de Ingeniería de Sistemas y Computación
Programa Académico de Maestría en Analítica e Inteligencia de Negocios
Cali, Abril de 2025

Contenido

1. INTRODUCCIÓN	1
2. PLANTEAMIENTO Y FORMULACIÓN DEL PROBLEMA	1
3. JUSTIFICACIÓN	2
4. OBJETIVOS.....	3
4.1 OBJETIVO GENERAL	3
4.2 OBJETIVOS ESPECÍFICOS	3
5. MARCO REFERENCIAL	3
5.1 ESTADO DEL ARTE	3
6. METODOLOGÍA.....	4
6.1 ACTIVIDADES A REALIZAR Y RESULTADOS ESPERADOS	4
6.2 CRONOGRAMA DE ACTIVIDADES	8
7. PRESUPUESTO	8
7.1 PRESUPUESTO GENERAL	8
7.2 PRESUPUESTO DETALLADO	8
Referencias	10

Listado de Tablas

Tabla 1. Actividades y resultados esperados con relación a cada objetivo específico.	6
Tabla 2. Cronograma de Actividades.....	8
Tabla 3. Presupuesto general del proyecto.	8
Tabla 4. Presupuesto de personal.....	9
Tabla 5. Presupuesto de Hardware.	9
Tabla 6. Presupuesto de otros rubros.	9

Listado de Figuras

No table of figures entries found.

1. INTRODUCCIÓN

El cambio climático ha intensificado la frecuencia y severidad de fenómenos climáticos extremos como la sequía y el anegamiento, lo cual afecta de manera significativa la calidad de germinación y la regeneración de semillas en cultivos estratégicos como el frijol común (*Phaseolus vulgaris*). Estas condiciones adversas no solo comprometen la producción agrícola, sino también la conservación y utilización eficiente de los recursos genéticos, pilares fundamentales para la seguridad alimentaria en regiones como América Latina y el Caribe (FAO, 2021).

En respuesta a estos desafíos, la estrategia metodológica FIGS (Focus Identification of Germplasm Strategy) ha surgido como una herramienta innovadora para seleccionar subconjuntos de accesiones con características deseadas, mediante el análisis de variables ecogeográficas (Mackay et al., 2007). FIGS ha sido reconocida por su capacidad para identificar subconjuntos de germoplasma con rasgos adaptativos específicos, utilizando datos ecogeográficos como proxies de selección. Según Bari et al. (2020), FIGS permite una exploración más dirigida y eficiente de las colecciones de germoplasma, facilitando la identificación de accesiones con características deseables en condiciones ambientales particulares. Esta metodología es especialmente útil en el contexto del cambio climático, donde la necesidad de cultivos adaptados a condiciones extremas es cada vez más urgente.

Paralelamente, el desarrollo de modelos predictivos mediante técnicas de aprendizaje automático (machine learning) permite analizar grandes volúmenes de datos climáticos históricos, identificar patrones relevantes y predecir el comportamiento de las accesiones bajo distintos escenarios ambientales (Khaki & Wang, 2019). La combinación de FIGS y machine learning ofrece una oportunidad única para fortalecer la toma de decisiones en programas de regeneración y conservación de germoplasma, al permitir seleccionar de forma anticipada aquellas accesiones con mayor probabilidad de germinar exitosamente en condiciones de estrés hídrico.

Este trabajo propone implementar un modelo de aprendizaje automático, apoyado en la estrategia FIGS, para predecir el potencial germinativo de accesiones de *Phaseolus vulgaris* conservadas en el banco de germoplasma del CIAT, a partir de datos climáticos históricos de sitios de recolección en Colombia. Esta propuesta busca aportar una herramienta analítica que facilite la priorización de accesiones para su regeneración en ambientes afectados por anegamiento o sequía, contribuyendo así a la eficiencia y sostenibilidad de los programas de recursos genéticos.

El resto del documento está organizado de la siguiente manera. Capítulo 2 describe el planteamiento y enunciado del problema. Capítulo 3 explica la justificación para desarrollar el trabajo de grado. Capítulo 4 muestra los objetivos, general y específicos. Capítulo 5 detalla el estado del arte. Capítulo 6 presenta la metodología, actividades y cronograma del proyecto y el capítulo 7 se especifica los costos para el proyecto.

2. PLANTEAMIENTO Y FORMULACIÓN DEL PROBLEMA

A pesar de contar con colecciones amplias de accesiones conservadas in situ, no siempre se dispone de herramientas analíticas que permitan predecir con antelación cuáles materiales presentan un mayor potencial adaptativo a condiciones ambientales extremas. La información ecogeográfica de los sitios de recolección, junto con datos climáticos históricos, representa una fuente valiosa aún subutilizada en los procesos de toma de decisiones para la regeneración eficiente de germoplasma.

La estrategia metodológica FIGS (Focus Identification of Germplasm Strategy) ha demostrado ser eficaz para identificar subconjuntos de accesiones con características deseables, a partir de variables ambientales del lugar de origen. Sin embargo, su potencial se amplifica al integrarse con técnicas modernas de aprendizaje automático y minería de datos, que permiten modelar relaciones complejas entre múltiples variables climáticas, geográficas y

biológicas (Mackay et al., 2007).

El problema central de este trabajo radica, entonces, en la falta de modelos predictivos integrados que utilicen tanto la estrategia FIGS como algoritmos de machine learning, para seleccionar accesiones con alta probabilidad de germinar en ambientes sujetos a sequía o anegamiento. Esta carencia limita la eficiencia de los programas de regeneración, puede conducir a la pérdida de recursos y compromete los esfuerzos de adaptación al cambio climático en el ámbito agrícola.

Frente a este escenario, se plantea la siguiente pregunta de investigación:

¿Cómo implementar un modelo de Machine Learning, apoyado en la estrategia metodológica FIGS (Focus Identification of Germplasm Strategy), para predecir accesiones del género *Phaseolus vulgaris* con potencial adaptativo a condiciones de sequía y anegamiento, utilizando variables ecogeográficas y técnicas de minería de datos?

Responder a esta pregunta permitirá avanzar hacia una gestión más inteligente de los recursos genéticos, optimizar los procesos de regeneración y priorizar aquellas accesiones con mayor viabilidad en condiciones climáticas adversas, contribuyendo así a la sostenibilidad del sistema agrícola colombiano.

3. JUSTIFICACIÓN

La creciente variabilidad climática, caracterizada por eventos extremos como sequías y anegamientos, plantea desafíos significativos para la agricultura en Colombia. Estos fenómenos afectan la germinación y regeneración de semillas, especialmente en cultivos estratégicos como el frijol común (*Phaseolus vulgaris*), comprometiendo la seguridad alimentaria y la sostenibilidad agrícola.

En este contexto, la estrategia FIGS (Focused Identification of Germplasm Strategy) emerge como una herramienta eficaz para identificar subconjuntos de germoplasma con características adaptativas específicas, mediante el análisis de variables ecogeográficas de los sitios de recolección. La integración de FIGS con técnicas de aprendizaje automático (Machine Learning) permite modelar relaciones complejas entre variables climáticas, geográficas y biológicas, facilitando la predicción del comportamiento de las accesiones bajo condiciones ambientales específicas. ScienceDirect

Implementar un modelo predictivo que combine FIGS y Machine Learning ofrece múltiples beneficios:

- Optimización de la regeneración de germoplasma: Al identificar accesiones con mayor probabilidad de germinar en condiciones adversas, se mejora la eficiencia en la conservación y uso de recursos genéticos.
- Sostenibilidad ambiental: La selección precisa de accesiones adaptadas reduce la necesidad de insumos adicionales, como agua y agroquímicos, minimizando el impacto ambiental.
- Innovación en la gestión agrícola: El uso de tecnologías avanzadas en la toma de decisiones fortalece los programas de mejoramiento y conservación de cultivos, alineándose con los objetivos de desarrollo sostenible.
- Generar un subconjunto de accesiones de importancia para uso en condiciones de sequía o anegamiento.

Este proyecto, enfocado en el Programa de Recursos Genéticos del CIAT en Palmira, Colombia, busca desarrollar una herramienta analítica que facilite la priorización de accesiones para su regeneración en ambientes afectados por estrés abiótico, contribuyendo así a la resiliencia del sistema agrícola colombiano. .

4. OBJETIVOS

4.1 Objetivo General

Implementar un modelo de Machine Learning, apoyado en la estrategia metodológica FIGS (Focus Identification of Germplasm Strategy), para predecir accesiones del género *Phaseolus vulgaris* con potencial adaptativo a condiciones de sequía y anegamiento, utilizando variables ecogeográficas y técnicas de minería de datos.

4.2 Objetivos Específicos

- 1) Diseñar e implementar un proceso ETL (extracción, transformación y carga) que permita recolectar, limpiar y estandarizar datos climáticos históricos, geográficos y de pasaporte, e integrarlos en una bodega de datos estructurada que soporte la trazabilidad, consulta y análisis de información relevante para el proceso de regeneración de semillas de frijol.
- 2) Aplicar la estrategia FIGS (Focus Identification of Germplasm Strategy) para generar subconjuntos focales de accesiones, utilizando variables ecogeográficas como proxy de rasgos adaptativos a estrés hídrico (sequía y anegamiento).
- 3) Implementar modelos de Machine Learning para predecir el potencial adaptativo de las accesiones priorizadas, evaluando su desempeño mediante métricas de clasificación, con el fin de validar su aplicabilidad en procesos de regeneración y conservación.

5. MARCO REFERENCIAL

5.1 Estado del Arte

El concepto de agricultura inteligente ha evolucionado significativamente con la integración de tecnologías avanzadas como sensores, plataformas de datos y algoritmos de aprendizaje automático (ML), los cuales permiten optimizar prácticas agrícolas con base en evidencia (Castillo Méndez & Camacho Castro, 2025). Estas herramientas son cada vez más utilizadas para la predicción de variables agroclimáticas, la evaluación de la calidad del suelo y la toma de decisiones agronómicas. Por ejemplo, tecnologías como el Agro-Deep Learning Framework (ADLF) han demostrado su efectividad en la optimización de prácticas agrícolas sostenibles. Este marco aprovecha la agricultura de precisión para mejorar la calidad de los cultivos y reducir el impacto ambiental. Estas técnicas no solo son aplicables a cultivos de gran escala, sino también a sistemas más especializados como la regeneración de semillas de frijol y forrajes tropicales. Por ejemplo, tecnologías como el Agro-Deep Learning Framework (ADLF) han demostrado su efectividad en la optimización de prácticas agrícolas sostenibles al reducir el uso de insumos y aumentar la calidad del cultivo (Khaki & Wang, 2019).

En los últimos años, el aprendizaje automático (ML, por sus siglas en inglés) ha cobrado una relevancia creciente en el ámbito agrícola, particularmente en tareas como la predicción del rendimiento de cultivos y el pronóstico de

variables meteorológicas. Diversos estudios han demostrado la eficacia de los modelos de ML al aplicar técnicas de análisis sobre datos provenientes de teledetección, índices de vegetación e información climática, logrando resultados prometedores en la estimación del rendimiento agrícola (Sadenova et al., 2023; Garcia-Arteaga et al., 2020).

Entre las arquitecturas más utilizadas, los bosques aleatorios (random forests) y las redes neuronales destacan por su alta precisión en tareas de predicción, aunque su rendimiento puede variar dependiendo del tipo de cultivo y las variables utilizadas como entrada (Garcia-Arteaga et al., 2020). Por otra parte, los modelos de ML también han sido empleados para predecir condiciones meteorológicas clave para la agricultura, como la temperatura, las precipitaciones y la humedad relativa, lo que permite a los agricultores tomar decisiones fundamentadas para mejorar tanto la calidad como el rendimiento de los cultivos (Castillo Méndez & Camacho Castro, 2025).

Los modelos de ML han demostrado gran capacidad para predecir atributos agronómicos en diferentes cultivos. Tavares et al. (2024) reportaron que modelos como Random Forest y Support Vector Machines (SVM) alcanzaron altos niveles de precisión en la predicción de necesidades de nitrógeno en frijol, utilizando espectroscopía NIR.

Por otra parte, la estrategia FIGS (Focused Identification of Germplasm Strategy) ha sido reconocida por su capacidad para generar subconjuntos de germoplasma con características adaptativas, utilizando datos ecogeográficos como variables proxy de selección (Mackay et al., 2007). FIGS parte del supuesto de que los rasgos adaptativos de una planta están influenciados por el ambiente de origen, por lo cual es posible predecir características como tolerancia a la sequía o al anegamiento mediante el análisis ambiental y climático del sitio de colección (Bari et al., 2020). El enfoque FIGS ha sido validado en diversos cultivos, permitiendo reducir el número de accesiones a evaluar en laboratorio o campo, y priorizar aquellas con mayor probabilidad de éxito para conservación, regeneración o mejoramiento (Khazaei et al., 2013).

Por último, la construcción de bodegas de datos y la implementación de procesos ETL (extracción, transformación y carga) son prácticas clave en entornos de inteligencia de negocios aplicados a la agricultura. Estos procesos permiten consolidar datos históricos, geográficos y experimentales desde diversas fuentes, asegurando su disponibilidad y trazabilidad para análisis posteriores (Castillo Méndez & Camacho Castro, 2025). El desarrollo de infraestructuras analíticas con arquitecturas orientadas a datos mejora la calidad de los modelos predictivos. En proyectos recientes, esta integración ha facilitado la creación de sistemas de soporte para la toma de decisiones en procesos como la regeneración de semillas y el monitoreo de variables agroclimáticas (Dilmurat et al., 2022). En tareas de predicción de germinación, modelos de deep learning aplicados a imágenes de semillas han logrado resultados con precisión superior al 90%, lo cual evidencia el potencial de la inteligencia artificial en la toma de decisiones para bancos de germoplasma (Nehoshtan et al., 2021).

6. METODOLOGÍA

6.1 Actividades a Realizar y Resultados Esperados

El ciclo de vida de análisis de datos en ambientes Big Data define 6 fases (Descubrimiento, preparación de datos, planeación del modelo, construcción del modelo, comunicar los resultados y operacionalizar). El desarrollo del proyecto se basará en estas fases, dado el alcance del proyecto se llevará hasta la fase 5, comunicar los resultados. Esto permitirá llevar control sobre el avance en las actividades del proyecto, con respecto al cronograma de actividades y seguimiento del cumplimiento de los objetivos.

En la fase 1, descubrimiento, consta de algunas actividades para desarrollar el contexto del problema, para ello se realiza indagación sobre el dominio del problema para conocer el área de trabajo, se debe aprender e investigar el problema y definir el reto a resolver. Además, se identifican fuentes de datos disponibles.

Fase 2, Limpieza de los datos recolectados. preparación de los datos, incluye los pasos de exploración, preprocesamiento y transformación de los datos antes de modelar y analizar, y se ejecutan las ETL necesarias.

Fase 3, planeación del modelo, se identifican las técnicas de análisis exploratorio que se aplicarán al caso de estudio por lo cual se deben entender los datos a profundidad. Para tal fin, se exploran los datos, identificando relaciones entre variables y finalmente, se seleccionan las variables y las técnicas a aplicar.

Fase 4, construcción del modelo. Para efectos de este proyecto se realizará analítica descriptiva mediante la implementación de algunas técnicas de análisis exploratorio de datos. En esta fase se define el conjunto de datos con todas las condiciones para los análisis y se ejecutan las técnicas definidas en la fase anterior.

Fase 5, comunicar los resultados, en esta fase se evalúan los resultados, se identifican los hallazgos relevantes y se realiza el informe final para mostrar los resultados.

Fase 6, implementar el prototipo funcional, evaluar la precisión del modelo y aplicar ajustes finales.

Tabla 1. Actividades y resultados esperados con relación a cada objetivo específico.

Objetivo	Actividad	Resultado(s) Esperado(s)
Diseñar e implementar un proceso ETL (extracción, transformación y carga) que permita recolectar, limpiar y estandarizar datos climáticos históricos, geográficos y de pasaporte, e integrarlos en una bodega de datos estructurada que soporte la trazabilidad, consulta y análisis de información relevante para el proceso de regeneración de semillas de frijol.	1. Obtener datos históricos de regeneración de frijol. 2. Obtener resultados históricos de evaluaciones calidad de germinación 3. Recolectar datos climáticos históricos de Colombia. 4. Obtener ubicación geográfica y altimetría de estaciones de cultivo. 5. Transformar los datos recolectados ejecutando los ETL's necesarios. 6. Diseño y creación de la bodega de datos. 7. Integración de los datos obtenidos de las diferentes fuentes de datos.	1. Base de datos consolidada con datos históricos de regeneración, clima, geografía y altimetría. 2. Reporte de calidad de los datos recolectados, identificando inconsistencias y lagunas. 3. ETL que permita la integración de todos los datos recopilados 4. Bodega de base de datos con los datos integrados listos para ser consultados.
Aplicar la estrategia FIGS (Focus Identification of Germplasm Strategy) para generar subconjuntos focales de accesiones, utilizando variables ecogeográficas como proxy de rasgos adaptativos a estrés hídrico (sequía y anegamiento).	8. Analizar datos espaciales para encontrar grupos ecogeograficos. 9) Usar coordenadas de los sitios de recolección para extraer las variables climáticas y ambientales específicas de cada punto geográfico. 10) Definir subconjuntos focales de accesiones con base en la coincidencia entre condiciones ambientales extremas y presencia de accesiones en esos ambientes.	1. Conjunto limpio y estructurado de datos de accesiones con ubicación geográfica validada.. 2. identificación clara de los ambientes extremos (alta sequía / anegamiento). 3. Subconjuntos focales de accesiones priorizadas para cada tipo de estrés hídrico. 4. Dataset final listo para alimentar los modelos de machine learning en la siguiente fase.
Objetivo	Actividad	Resultado(s) Esperado(s)

Implementar modelos de Machine Learning para predecir el potencial adaptativo de las accesiones priorizadas, evaluando su desempeño mediante métricas de clasificación, con el fin de validar su aplicabilidad en procesos de regeneración y conservación.	11. Seleccionar del algoritmo de Machine Learning más apropiado. 12. Entrenar el modelo utilizando los datos preparados. 13. Validar y ajustar para optimizar la predicción 14. Implementar un prototipo funcional para predicción en tiempo real.	1. Análisis exploratorio visual y descriptivo, con patrones identificados. 2. Algoritmo de machine learning seleccionado y justificado. 3. Modelo entrenado y validado con métricas iniciales (precisión, recall, etc.). 4. Prototipo funcional documentado para pruebas iniciales. 5. Informe con métricas de validación y ajuste del modelo, destacando precisión y robustez. 6. Prototipo funcional implementado para predicciones en tiempo real, con interfaz
--	---	---

6.2 Cronograma de Actividades

El trabajo de grado se desarrollará durante el año 2024. La tabla 2, muestra el cronograma y duración de las actividades que se realizarán.

Tabla 2. Cronograma de Actividades

Actividad	Duración (semanas)	Marzo			Abril				Mayo				Junio				Julio				Agosto				Septiembre				Octubre				Noviembre				Diciembre				
		1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24	25	26	27	28	29	30	31	32	33	34	35	36	37	38	39	40
1	4																																								
2	4																																								
3	5																																								
4	5																																								
5	5																																								
6	5																																								
7	5																																								
8	5																																								
9	5																																								
10	5																																								
11	3																																								
12	3																																								
13	3																																								
14	3																																								

7. PRESUPUESTO

7.1 Presupuesto general

En la tabla 6 se presenta el presupuesto general para el desarrollo exitoso del presente proyecto.

Tabla 3. Presupuesto general del proyecto.

RUBROS	VALOR (Pesos)
Personal	\$ 62'320.000
Hardware	\$ 35'000.000
Software	\$ 0
Publicaciones	\$ 0
Papelería y otros	\$ 100.000
TOTAL PRESUPUESTO	\$ 97'420.000

7.2 Presupuesto detallado

En las siguientes tablas se evidencia el presupuesto detallado por cada rubro y la fuente de financiación.

Tabla 4. Presupuesto de personal.

Nombre De Participante	Función	Meses De Vinculación	Dedicación (H/S)	Costo Por Hora	Costo Total (Pesos)	Fuente de financiación
Ph.D.	Director	9	2	\$ 200.000	\$ 14'400.000	Universidad del Valle
Ph.D.	Co-Director	7	2	\$ 200.000	\$ 11'200.000	Universidad Nacional
Guillermo Andrés Hernández	Desarrollador	9	12	\$ 85.000	\$ 36'720.000	Autor
TOTAL COSTO PERSONAL					\$ 62'320.000	

Tabla 5. Presupuesto de Hardware.

Equipo	Justificación	Costo (Pesos)	Fuente de financiación
Servidores del Programa de Recursos Genéticos - CIAT	Configuración de ambientes para gestión de los datos, ejecutar pruebas (En especie)	\$ 27'000.000	Programa de Recursos Genéticos
Portátil	Portátil para desarrollo	\$ 8'000.000	Autor
TOTAL COSTO HARDWARE		\$ 35'000.000	

Tabla 6. Presupuesto de papelería y otros rubros.

Concepto	Justificación	Costo (Pesos)	Fuente de financiación
Impresiones y fotocopias	Material requerido físicamente, impresión del documento final.	\$ ±100.000	Autor
TOTAL COSTO OTROS		\$ ±100.000	

Referencias

- Domingues, T., Brandão, T., & Ferreira, J. C. (2022). Machine learning for detection and prediction of crop diseases and pests: A comprehensive survey. *Agriculture*, 12(9), 1350. <https://doi.org/10.3390/agriculture12091350>
- Saldaña Valenzuela, S. (2023). Inteligencia artificial: detección de enfermedades en el cultivo de frijol. *Revista Naturaleza, Sociedad y Ambiente*, 10(1), 53–58. <https://doi.org/10.37533/cunsurori.v10i1.87>
- Kumar, R., et al. (2023). An intellectual model of pest detection and classification using enhanced optimization-assisted single shot detector and graph attention network. *Agriculture*.
- Naeem, F., et al. (2023). A smart application as solution for diagnosis of rice diseases in Pakistan: An image processing approach. *Computers and Electronics in Agriculture*.
- Chen, Y., et al. (2022). Early plant disease detection by Raman spectroscopy: An open-source software designed for the automation of preprocessing and analysis of spectral dataset. *Journal of Plant Science*.
- López, A., et al. (2023). Analyzing the performance of deep convolutional neural network models for weed identification in potato fields. *Precision Agriculture*.
- Zhao, L., et al. (2023). Few-shot agricultural pest recognition based on multimodal masked autoencoder. *Remote Sensing in Agriculture*.
- Zhang, W., et al. (2023). Prediction of soil organic carbon fractions in tropical cropland using a regional visible and near-infrared spectral library and machine learning. *Ecological Indicators*, 130.
- Microsoft. (2024, 19 de noviembre). Guías de diseño y de arquitectura de índices de SQL Server. Microsoft Learn. <https://learn.microsoft.com/es-es/sql/relational-databases/sql-server-guides?view=sql-server-ver16>
- Microsoft. (2024, 19 de noviembre). Documentación técnica de SQL Server. Microsoft Learn. <https://learn.microsoft.com/es-es/sql/sql-server/?view=sql-server-ver16>
- Pentaho. (2015, 2 de septiembre). Spoon User Guide - Pentaho Data Integration. Pentaho Community Wiki. <https://pentaho-community.atlassian.net/wiki/spaces/EAI/pages/370966839/Spoon%2BUser%2BGuide>
- Bioversity International. (s.f.). GGCE Community Edition User Manual. Programa de Recursos Genéticos del CIAT. <https://genebankplatform.bioversityinternational.org>
- Centro Internacional de Agricultura Tropical (CIAT). (s.f.). Programa de Recursos Genéticos. CIAT. <https://ciat.cgiar.org>
- https://agroavances.com/img/publicacion_documentos/Manual%20de%20Procedimientos-Certificacion%20Sanitaria%20Frijol-Forrajes2.pdf
- Debouck, D. G. (2010). En tiempos de turbulencias climáticas y alimentarias, el Programa de Recursos Genéticos del CIAT ofrece “una semilla de soluciones”. Presentación Día de Puertas Abiertas, CIAT, Palmira.

<https://cgspace.cgiar.org/bitstreams/b8b0bd5d-a4f1-427b-bcb5-0903ba2ddadd/download>

- FAO. (2021). The State of the World's Land and Water Resources for Food and Agriculture – Systems at breaking point. Food and Agriculture Organization of the United Nations. <https://doi.org/10.4060/cb9910en>
- Khaki, S., & Wang, L. (2019). Crop yield prediction using deep neural networks. *Frontiers in Plant Science*, 10, 621. <https://doi.org/10.3389/fpls.2019.00621>
- Mackay, M., Street, K., & Bansal, U. (2007). Focused Identification of Germplasm Strategy (FIGS): A data mining approach to identify plant genetic resources with adaptive traits. *Euphytica*, 154(3), 351–366. <https://doi.org/10.1007/s10681-006-9323-0>
- Bari, A., Street, K., Mackay, M., Endresen, D. T. F., De Pauw, E., & Amri, A. (2020). Focused Identification of Germplasm Strategy (FIGS): Polishing a diamond in the rough. *Agricultural Systems*, 182, 102857. <https://doi.org/10.1016/j.agsy.2020.102857>
- Castillo Méndez, R., & Camacho Castro, J. (2025). Aplicación de técnicas de aprendizaje automático en la predicción de variables meteorológicas para la agricultura. *Revista Colombiana de Agrotecnología*, 15(1), 45–60.
- Dilmurat, K., Sagan, V., Maimaitijiang, M., Moose, S., & Fritschi, F. B. (2022). Estimating Crop Seed Composition Using Machine Learning from Multisensory UAV Data. *Remote Sensing*, 14(19), 4786. <https://doi.org/10.3390/rs14194786>
- Garcia-Arteaga, J. D., Romero, R. A., & González, F. A. (2020). Predictive modeling of crop yields using remote sensing and machine learning: A review. *Computers and Electronics in Agriculture*, 175, 105576.
- Khazaei, H., Street, K., Bari, A., Mackay, M., & Stoddard, F. L. (2013). The FIGS (Focused Identification of Germplasm Strategy) approach identifies traits related to drought adaptation in *Vicia faba* genetic resources. *PLOS ONE*, 8(5), e63107. <https://doi.org/10.1371/journal.pone.0063107>
- Nehoshtan, Y., Carmon, E., Yaniv, O., Ayal, S., & Rotem, O. (2021). Robust seed germination prediction using deep learning and RGB image data. *Scientific Reports*, 11, 22030. <https://doi.org/10.1038/s41598-021-01712-6>
- Ramírez Gómez, L. (2020). Evaluación del estado fisiológico de cultivos mediante algoritmos de aprendizaje automático. *Agricultura Digital*, 8(2), 30–42.
- Tavares, M. S., Silva, C. A. A. C., Regazzo, J. R., et al. (2024). Performance of Machine Learning Models in Predicting Common Bean (*Phaseolus vulgaris* L.) Crop Nitrogen Using NIR Spectroscopy. *Agronomy*, 14(8), 1634. <https://doi.org/10.3390/agronomy14081634>
- Zhang, J., Li, Y., Chen, J., Wu, Y., & Li, Y. (2023). Estimating organic carbon fractions in tropical soils using visible-near-infrared spectroscopy and multivariate models. *Geoderma Regional*, 32, e00645.
- Mackay, M. C., Street, K., Mitchell, J., Borda, A., Leleji, O., & Michael, P. (2007). Focused identification of germplasm strategy (FIGS): A novel approach to harnessing the diversity of genebanks to support crop improvement.